Universitá Politecnica Delle Marche

INGEGNERIA INFORMATICA E DELL'AUTOMAZIONE PROGETTO DATA SCIENCE 2021-2022

Analisi dei Boardgames mediante l'uso di PowerBI



Studenti:
Massimo Ciaffoni
Simone Cappanera

Indice

1	Power BI			
	1.1	Dataset	2	
	1.2	ETL e caricamento dei dati	4	
2	Des	crizione delle visualizzazioni	6	
	2.1	Vista Parole più utilizzate	7	
	2.2	Vista Ricezione Mediatica	8	
	2.3	Vista Autori	10	
	2.4	Vista Categorie	12	
	2.5	Vista Sito	14	

Capitolo 1

Power BI

Power BI è un software di business intelligence lanciato da Microsoft nel 2013. Una delle caratteristiche che distingue questo strumento dagli altri è la possibilità di importare grafici aggiuntivi attraverso una vetrina accessibile direttamente dall'interfaccia dell'applicazione, facendo uso di script personalizzati scritti nel linguaggio R. Grazie a ciò, è possibile fare analisi più personalizzate ed approfondite rispetto ai principali competitor. Un'altra delle caratteristiche che Power BI mette a disposizione è l'uso dello strumento Power Query per le operazioni di ETL. Con Power Query, infatti, è possibile importare o connettersi a dati esterni e quindi modellare tali dati; ad esempio, si può rimuovere una colonna, modificare un tipo di dati o unire tabelle in base alle proprie esigenze. Successivamente, è quindi possibile caricare la query con il dataset ripulito direttamente in PowerBI per creare grafici e report.

1.1 Dataset

Il dataset utilizzato per l'analisi è quello relativo alla descrizione dei 20.000 giochi da tavolo, registrati presso il sito boardgamegeek.com. Il dataset è disponibile presso il seguente link:

https://www.kaggle.com/datasets/extralime/20000-boardgames-dataset

In particolare, esso è ricco di informazioni relative sia al gioco da tavolo in sé (descrizione, artisti, designer, publisher, ecc...), sia agli utenti del sito (voto medio recensioni, numero di commenti, visualizzazioni, ecc...). Di seguito è presente una tabella riassuntiva di tutti i campi presenti nel dataset, compresi il tipo di dati e la descrizione.

Campo	Tipo	Descrizione
ObjectId	Number	Codice identificativo del boardgame.
Name	Text	Titolo del boardgame.
Yearpublished	Number	Anno di pubblicazione del boardgame.
SortIndex	Number	Rank del boardgame sul sito bbg.com
MinPlayer	Number	Numero di giocatori minimi per il publisher.
MaxPlayers	Number	Numero di giocatori massimi per il publisher.
MinPlayTime	Number	Tempo minimo richiesto per una partita per il publisher.
MaxPlayTime	Number	Tempo massimo richiesto per una partita per il publisher.
MinAge	Number	Età minima per il publisher.
Min_Community	Text	Numero di giocatori minimi per la community Se non disponibile è segnalato con 'NA'.
Max_Community	Text	Numero di giocatori massimi per la community Se non disponibile è segnalato con 'NA'.
TotalVotes	Number	Numero totale di voti della community.
DI A	m. ,	Età minima per la community.
PlayerAge	Text	Se non disponibile è segnalato con '(no votes)'.
LanguageDependance	Number	Rank sul testo in game richiesto da leggere durante una partita. Varia da 0 a 5 (vedere riferimento per il significato).
UserRated	Number	Numero di utenti che hanno recensito il gioco.
Average	Number	Voto medio da 1 a 10.
Baverage	Number	Voto dato dal sistema di anti-skewing.
Stddev	Number	Media della deviazione standard del voto.
AvgWeight	Number	Un rating complesso da 1 a 5.
NumWeight	Number	Numero di voti pesati.
NumGeekList	Number	Numero di geek che hanno il gioco in lista.
NumTraiding	Number	Numero di utenti che scambiano il gioco.
NumWanting	Number	Numero di utenti che vogliono il gioco.
NumComments	Number	Numero di commenti sul gioco.
SiteViews	Number	Numero di visualizzazioni sul gioco.
NumPlays	Number	Numero di volte che il gioco è stato giocato.
NumPlays Month	Number	Numero di partite al mese.
News	Number	Numero di articoli sul gioco.
Blogs	Number	Numero di blog relativi al gioco.
WebLink	Number	Numero di weblink relativi al gioco.
Podcast	Number	Numero di podcast relativi al gioco.
Label	Text	Categoria del gioco.
BoardGameDesigner Cnt	Number	Numero di designer che hanno lavorato al gioco.
BoardGameArtist Cnt	Number	Numero di artisti che hanno lavorato al gioco.
BoardGamePublisher Cnt	Number	Numero di publisher che hanno pubblicato il gioco.
BoardGameHonor Cnt	Number	Numero di premi vinti dal gioco.
BoardGameCategory Cnt	Number	Numero di categorie del gioco.
BoardGameMechanic Cnt	Number	Numero di meccaniche del gioco.
BoardGameExpansion Cnt	Number	Numero di espansioni per il gioco.
BoardGameVersion Cnt	Number	Numero di versioni per il gioco (lingua).
BoardGameFamily Cnt	Number	Numero di family del gioco.
BoardGameDesigner	Text	Lista dei designer che hanno lavorato al gioco.
BoardGameArtist	Text	Lista di artisti che hanno lavorato al gioco.
BoardGamePublisher	Text	Lista di publisher che hanno pubblicato il gioco.
BoardGameHonor	Text	Lista di premi vinti dal gioco.
BoardGameCategory	Text	Lista delle categorie del gioco.
BoardGameVersion	Text	Lista delle versioni del gioco.
BoardGameMechanic	Text	Lista delle meccaniche del gioco.
BoardGameExpansion	Text	Lista delle espansioni del gioco.
BoardGameFamily	Text	Lista delle family del gioco.
Description	Text	Descrizione del gioco.
Gamelink		Link della pagina del gioco su bbg.com
Gamennik	Text	Link dena pagina dei gioco su dog.com

Tabella 1.1: Elenco dei campi del dataset

1.2 ETL e caricamento dei dati

Prima dell'analisi vera e propria, il dataset è stato ripulito e trasformato utilizzando Power Query. Le operazioni sono state diverse ed hanno interessato diversi campi del dataset:

- Il campo **YearPublished** è stato filtrato per valori maggiori o uguali a 1800 in modo da escludere alcuni boardgames anomali con anno di uscita inferiore. Inoltre, il tipo di dato del campo è stato modificato in formato *date* in modo tale che fosse utilizzabile per un'analisi predittiva sui boardgames.
- I campi testuali $Min_community$ e $Max_community$ sono stati trasformati in tipo numerico andando a sostituire con il valore nullo tutti i valori 'NA' che indicavano l'assenza di informazione.
- Anche il campo *PlayerAge* è stato trasformato in tipo numerico in maniera simile ai precedenti sostituendo i valori '(no votes)' con il tipo nullo.
- I campi Baverage, Stddev, NumWeigth, Label, Gamelink, BoardGameFamiliy, BoardGameVersion, BoardGameExpansion sono stati eliminati in quanto non interessanti al fine dell'analisi.
- Il campo *Average* presentava alcuni problemi di formattazione, dunque il suo valore è stato trasformato in modo che fosse compreso tra 1 e 10 e poi, successivamente, arrotondato a due cifre significative dopo la virgola. Inoltre, il nome del campo è stato rinominato in *average_rate* in modo che fosse più riconoscibile in fase di analisi.
- In alcuni casi i valori dei campi BoardgameDesigner, BoardgameArtist ripetevano lo stesso valore del campo BoardgamePublisher. In questi casi il valore è stato sostituito con la stringa '(Unknown)' in modo da evitare errori in fase di analisi. Inoltre, nel caso in cui il numero di artisti o designer fosse definito come pari a 0 nei rispettivi campi count, il valore è stato sostituito con il valore nullo, in quanto nessun artista/designer ha lavorato al boardgame.
- In maniera analoga al passo precedente, il campo **Boardgame Category** dei record che presentavano un valore 0 nel *count* delle categorie è stato sostituito con un valore nullo.
- I campi BoardgameDesigner, BoardgameArtist, BoardgamePublisher, BoardgameCategory e BoardgameMechanic presentavano come valori liste di elementi, i quali sono stati separati per righe in modo da distinguere i vari designer, artisti, publisher e le varie meccaniche/categorie di

gioco. La divisione è stata effettuata eliminando i vari caratteri [] ", e separando i diversi elementi, scegliendo il carattere virgola come separatore. Ad esempio, il primo record del dataset presentava come valore di **Boardga**meDesigner "['Ananda Gupta""', 'Jason Matthews""']", il quale, dopo essere stato ripulito, è stato diviso in due righe. Queste righe presentano i due diversi valori dei designer Ananda Gupta e Jason Matthews. Questa divisione ha incrementato la dimensione del dataset fino a circa 944 mila righe, che non hanno comunque rallentato troppo l'analisi. Inoltre, questa divisione era necessaria in vista dell'analisi successiva dei diversi autori e delle diverse categorie dei boardgames.

• In alcuni valori dei campi precedenti, c'erano delle anomalie dovute all'inserimento di caratteri numerici all'interno dei diversi nomi e cognomi degli artisti/designer. Per questo motivo, tali cifre sono state eliminate in modo da rendere i campi più leggibili nella fase di analisi. Ad esempio, un record presentava il valore Philippe Guu00e9rin nel campo BoardgameArtist, il quale è stato trasformato in Philippe Guuerin.

```
"Risesse closes varie" - Table. Resolvations (Pholificate tips intere community", (Tabel", "gazalin", "boardgameeratin", "noundgates", "stade", "sourage," beardgameeratin")),
"Profitation tips were a "Table. TransformChampier(Photose colone welf", (Twerage", type text))),
"Profitation tips were a "Table. TransformChampier(Photose colone welf", (Twerage", type text))),
"Profitation tips were a "Table. TransformChampier(Photose colone welf", (Twerage", type text))),
"Profitation tips were a "Table. TransformChampier(Photose colone welf", (Twerage", type text))),
"Profitation tips were a "Table. TransformChampier(Photose colone and the state of the s
```

Figura 1.1: Porzione di schermata dell'editor avanzato di Power Query

Capitolo 2

Descrizione delle visualizzazioni

Le dashboard che sono state create in Power BI sono state suddivise in diversi campi di analisi. In particolare, sono state create le seguenti viste:

- Vista Parole più utilizzate: si sono analizzate le parole più ripetute nei diversi boardgames presenti nel dataset.
- Vista Recezione Mediatica: si è analizzata la ricezione del pubblico ai vari boardgames andando ad analizzare le recensioni, i podcast, le notizie ed altre informazioni.
- Vista Autori: si sono analizzati i diversi autori, designer e publisher che hanno pubblicato i boardgames negli anni.
- Vista Categorie: si sono analizzate diverse informazioni sui boardgames dividendoli per categorie.
- Vista Sito: si sono analizzate alcune informazioni del sito boardgamegeek.com relative al numero di visualizzazioni e ai commenti dei vari boardgames.

2.1 Vista Parole più utilizzate

La prima vista mostra quali sono le parole più utilizzate nei nomi dei vari boardgames e nelle loro descrizioni. Per fare ciò sono stati utilizzati due word cloud, un
tipo di grafico che illustra, sotto forma di una specie di nuvola (da qui il nome),
una lista di parole con colori e dimensioni differenti, in relazione all'importanza
che ognuna di queste assume nel contesto in cui è inserita. Il word cloud è uno dei
vari grafici messi a disposizione dal vasto marketplace di Power BI. Scendendo nel
dettaglio, il primo word cloud mostra chiaramente come le parole che compaiano
il maggior numero di volte nei nomi dei vari boardgames siano "Game", "Battle",
"Edition", "Black", "Card" e "War". Invece, andando ad analizzare il secondo
word cloud, si può notare come, in questo caso, le parole più utilizzate nelle descrizioni dei vari boardgames siano "game", "players" e la sua variante singolare
"player", "cards", "each" e "one".



Figura 2.1: Vista Parole più utilizzate

2.2 Vista Ricezione Mediatica

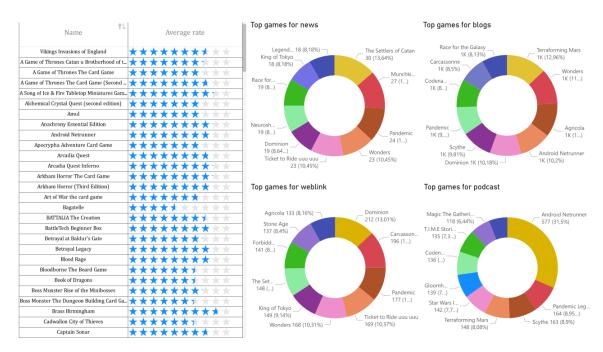


Figura 2.2: Vista Ricezione Mediatica

In questa vista è stata analizzata la ricezione mediatica dei diversi boardgames, sia per quanto riguarda le news, i blogs, i weblink ed i podcast ad essi relativi, sia per il voto medio che hanno ricevuto sul sito boardgamegeek.com. Scendendo nel dettaglio, i quattro grafici ad anello a destra mostrano delle top che evidenziano quali siano i boardgames, rispettivamente, con il maggior numero di news, blogs, weblink e podcast ad essi relativi. La tabella a sinistra, invece, messa a disposizione dal marketplace di Power BI, illustra per ogni boardgame il suo voto medio, in una scala da 1 a 10. La particolarità di questa tabella è che il punteggio è raffigurato con la rappresentazione visiva classica delle stelle, tipica nell'ambito delle recensioni, tenendo in considerazione che i voti decimali corrispondono a un riempimento solo parziale della stella. Quindi, per esempio, il gioco "BATTALIA The Creation", che ha un voto medio pari a 7,5 sul sito boardgamegeek.com, verrà rappresentato con sette stelle piene e una riempita solo per metà. In questa vista è presente un filtro per il nome dei boardgames, così che sia possibile selezionare solo un sottoinsieme di tutti i giochi da tavolo del sito. A tal proposito, la figura 2.3 mostra un filtraggio su cinque boardgames (Blood Bowl, Gloomhaven, Monopoly, UNO, Warhammer), che riduce drasticamente la dimensione della tabella dei voti medi. In questo modo è possibile, quindi, ottenere un'analisi più specifica indirizzata solo a un determinato sottoinsieme di boardgames d'interesse, oltre che una

visualizzazione complessivamente più pulita e chiara.

N.B. Di default le quattro top rappresenterebbero i primi dieci boardgames per numero di news, blogs, weblink e podcast; ma se, come nell'esempio, con il filtro su *name* si scelgono meno di dieci giochi da tavolo o se ne prende un sottoinsieme per cui meno di dieci hanno dei dati per questi quattro campi, ovviamente le top visualizzeranno un numero minore di boardgames.



Figura 2.3: Esempio di filtraggio sui boardgames

2.3 Vista Autori

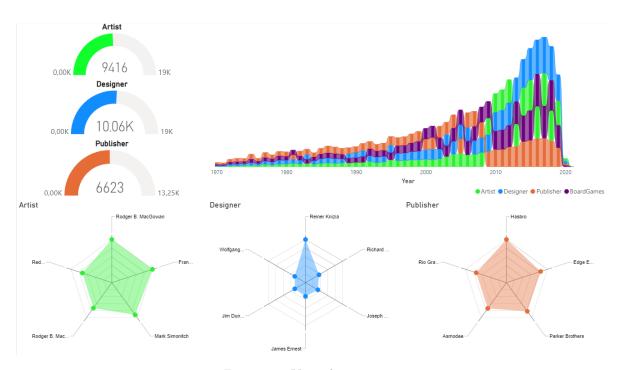


Figura 2.4: Vista Autori

La vista degli autori mostra una panoramica generale degli artisti, dei designer e dei publisher che hanno lavorato nello sviluppo dei vari boardgames. Ad ognuno di questi tre elementi è stato assegnato un colore ed è stato realizzato un KPI che ne indica la numerosità. Il *grafo a nastro* sulla destra mostra il numero di designer, artisti, publisher e di giochi da tavolo pubblicati negli anni; in particolare, la visualizzazione è stata filtrata per tutti i giochi da tavolo pubblicati dal 1970 in poi, in modo da compattare maggiormente la visualizzazione (infatti i boardgames pubblicati negli anni precedenti sono molti meno). Infine, in basso sono state realizzate, grazie all'uso dei radar charts messi a disposizione dal marketplace, delle top le quali mostrano gli artisti, i designer e i publisher che hanno lavorato alla realizzazione di più giochi da tavolo. La vista è stata realizzata andando a creare diversi filtri: uno per l'anno di pubblicazione, e tre per ogni classe di autore. Come si può notare nella figura 2.5, la vista è stata filtrata prendendo in considerazione il publisher ACE Peit Oy; in questo modo è possibile ottenere informazioni utili come gli artisti e i designer che hanno collaborato con il publisher, così come il numero e l'anno di pubblicazione dei vari boardgames. Dunque, utilizzando i vari filtri messi a disposizione, è possibile ottenere diverse informazioni aggiuntive su specifici autori o sui diversi boardgames pubblicati negli anni.

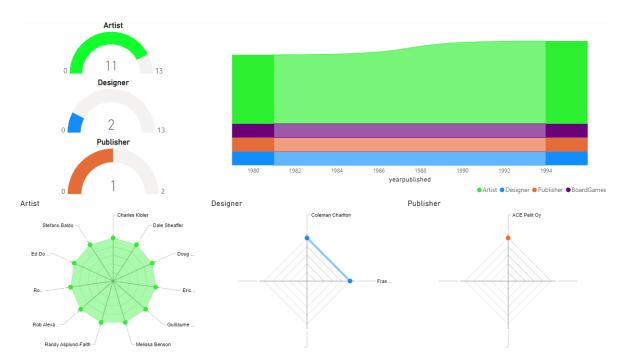


Figura 2.5: Esempio di filtraggio di publisher

2.4 Vista Categorie

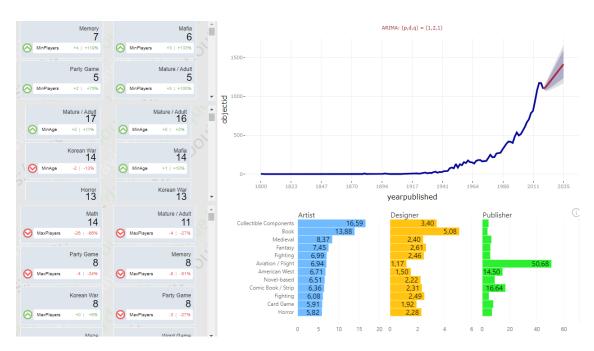


Figura 2.6: Vista Categorie

Questa vista mostra diverse informazioni sui boardgames in base alle categorie con cui questi sono classificati. I vari KPI sono stati realizzati utilizzando un Card KPI messo a disposizione dal marketplace. Questo grafico, posto a sinistra, mostra, per ogni categoria, il numero medio di giocatori minimi e massimi e quello dell'età minima consigliati dal publisher. Per ognuno di questi KPI viene effettuato un confronto tra il valor medio del publisher e quello consigliato dalla community; infatti, per ognuno di essi, viene definito se il valor medio del publisher sia maggiore o minore rispetto a quello consigliato dalla community, sia a livello nominale che percentuale (nel primo caso il **KPI** sarà segnato con una freccia verde, mentre nel secondo da una freccia rossa). Il grafo a barre, in basso a destra, mostra invece il numero medio di publisher, designer e artisti che hanno lavorato allo sviluppo dei boardgames, divisi per categoria. Infine, in alto a destra è presente un grafico che effettua un forecasting ARIMA del numero di boardgames in uscita per ogni anno. La visualizzazione, di default, utilizza un algoritmo in grado di ottimizzare i parametri del modello basandosi su alcuni criteri, tuttavia è comunque possibile specificare la stagionalità, i livelli di confidenza ed i valori massimi di P, D e Q. Anche per questa vista sono stati realizzati dei filtri, sia per l'anno di pubblicazione che per la categoria. A tal proposito, la figura 2.7 mostra un filtraggio su due categorie, il quale va a modificare la visualizzazione sull'andamento temporale e la

previsione delle uscite annuali; infatti questa previsione terrà ora in considerazione solo i boardgames delle categorie scelte. In questo modo è possibile avere una panoramica temporale per ogni singola categoria o per sottoinsiemi di categorie.

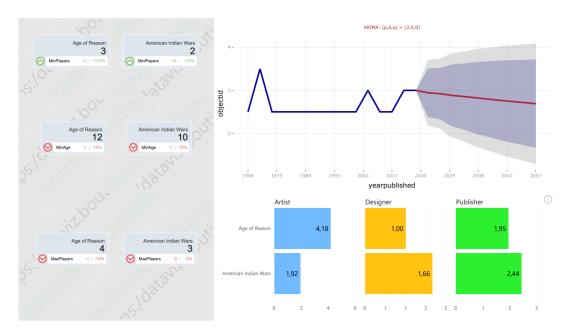


Figura 2.7: Esempio di filtraggio sulle categorie

2.5 Vista Sito

L'ultima vista prende in considerazione tutte quelle caratteristiche del dataset relative al sito boardqameqeek.com, il quale raccoglie alcune informazioni sui suoi utenti (commenti, visualizzazioni, ecc...). Una prima visualizzazione, posta a destra, è stata realizzata utilizzando un tornado chart, il quale mette a confronto, per ogni singolo boardgame del sito, il numero di utenti che hanno dichiarato di volerlo acquistare e il numero di utenti disposti a scambiarlo. Come si può notare nella maggior parte dei casi, il numero di persone disposte ad acquistare il gioco da tavolo sono molte di più rispetto a quelle disposte a scambiarlo. In alto a sinistra, invece, è presente un bubble chart, il quale mette a confronto, per ogni categoria, il numero medio di commenti, visualizzazioni e geeks. In particolare, l'asse delle ascisse rappresenta il valor medio delle visualizzazioni nel sito, mentre quello delle ordinate mostra il numero medio di commenti. Inoltre, la grandezza delle sfere indica il numero di geeks che hanno boardgames di quella categoria nella propria lista. Infine, in basso a sinistra, l'ultima visualizzazione è una matrice di correlazione, che mostra come i vari dati raccolti dal sito siano correlati tra loro. Come previsto, molte delle caratteristiche sono in forte correlazione tra loro, come, ad esempio, il numero dei commenti e il numero di geeks.

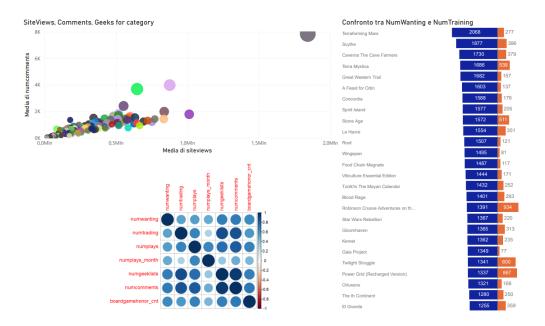


Figura 2.8: Vista Sito